

Evolution-AI.Design 综合审计报告

报告日期: 2026-08-10

审计范围: 2026-08-09 ~ 2026-08-10 全量工作

涵盖: 项目清理归档、死代码审计、LLM 微调与 RAG 修复、Docker 容器化

一、项目概览

技术架构 (4 层)

层	技术栈	核心目录
前端	Vue 3 + Vite + Pinia + Three.js + Element Plus	<code>src/</code> (8 个页面、4 个组件、4 个 store)
后端	FastAPI + SQLite + Uvicorn	<code>backend/</code> (10 条路由: ai / car / build / export / quality / workflow 等)
算法	Cython 加速 NURBS + 参数化车身 + A 级曲面 SOP 评估	<code>algorithm_model/</code> (car_modeling / freeform / surface_quality / storyboard)
AI/LLM	Qwen2.5-0.5B + QLoRA + RAG (Ollama API 兼容)	<code>scripts/llm_server.py</code> + <code>data/training/</code>

核心功能

- 参数化车身生成: SAE 坐标系驱动, L/W/H/WB 等参数控制 17 个组件、33 个曲面
- NURBS 曲面质量评估: G0/G1/G2 连续性检查、ISO 曲率梯度比、CV 变异系数、R 角检查
- SOP 检查清单: 13 项检查、183 条记录、67 条自动化、自动化通过率 79%
- AI 专家问答: 基于微调模型 + RAG 检索的 NURBS 知识问答服务

二、8 月 9 日审计记录

2.1 前端图片加载修复

问题: Designer.vue 中车型图片直接调用远程 `text_to_image` API, 浏览器端因缺少 IDE 鉴权环境返回 `net::ERR_FAILED`。

修复措施:

- `src/config/carPresets.js` : 新增 `generatePresetImage()` 函数, 在模块初始化时为 19 款车型预渲染本地 SVG dataURL (含品牌色和尺寸标注)
- `src/views/Designer.vue` : 删除远程加载逻辑和 `imageCache / cleanupImageCache` 死代码, `loadImage()` 改为 `prepareModelImage()`, `getImageState()` 默认返回 `loaded`

代码审查发现:

- `prepareModelImage` 检查条件逻辑缺陷 (覆盖预置图片) → 已修复
- `getBrandKeyForModel` 变量遮蔽问题 → 已修复

验证结果: 控制台无 error 和 ERR_FAILED, 模型图片、Car3D/Car2D 组件、参数滑块、AI 面板、颜色选择器、导航栏全部正常。

2.2 项目归档清理

动作: 审核项目全部文件, 将非核心废弃文件归档到 `_archive/`。

归档分类 (共 ~80+ 文件) :

目录	内容	文件数
<code>_archive/dirs/3d_automation/</code>	3D 交互系统、AI 工作流文档、思维导图	~25
<code>_archive/dirs/docs/</code>	历史完结报告 (W1~W4、M2.5)、产品规格、架构设计	~30
<code>_archive/dirs/evolution_ai_demo_w2d1/</code>	旧版前端构建产物	~25
<code>_archive/dirs/core/</code>	旧版核心代码 (<code>car_surface.py</code> 、 <code>full_body.py</code>)	3
<code>_archive/dirs/codeact/</code>	CodeAct 测试脚本	2
<code>_archive/dirs/SUPER_AGENT/</code>	旧版 Agent 脚本	1
<code>_archive/dirs/generation/</code>	旧版参数化生成脚本	1
<code>_archive/dirs/viewer/</code>	旧版 API 服务器	1
<code>_archive/docs/</code>	旧文档 (CHANGELOG、README_DEMO、SOLUTION_ARCHITECTURE)	3
<code>_archive/misc/</code>	杂项 HTML 演示、Plotly 截图	6
<code>_archive/scripts/</code>	过期启动脚本、Streamlit/Plotly 测试	~20

根目录保留的核心文件: 前端源码 `src/`、后端源码 `backend/`、算法模型 `algorithm_model/`、脚本 `scripts/`、数据 `data/`、测试 `tests/`、Docker 配置、构建配置。

2.3 整体测试验证

结果: 201 个测试全部通过, 0 失败, 9 条警告 (与本次清理无关)。

2.4 Git 提交

- Commit: `c6a65af3` , 分支: `v1.01-reconstruct`
- 涉及 139 个文件变更 (137 个删除 = 归档、2 个修改 = `carPresets.js` + `Designer.vue`)
- 76 行新增、33,974 行删除

2.5 后端接口验证

接口	方法	状态	说明
<code>/api/v1/car/parameters</code>	GET	正常	返回 5 大类参数树
<code>/api/v1/car/components</code>	GET	正常	返回 17 个组件
NURBS 曲面生成	POST	正常	生成 33 个曲面 + 33 个组件
<code>/api/v1/ai/dataset-stats</code>	GET	404	后端 <code>main.py</code> 未注册 AI 路由模块 (后续已修复)

2.6 测试数据蒸馏

- 清理 15 个未跟踪临时文件 (~4MB) : pytest 生成的 `model_*` 目录和 NURBS 截图
- 更新 `.gitignore` : 新增 `data/exports/model_*/` 和 `data/step/nurbs_a_class_*.png` 规则
- 蒸馏为训练材料: 3 个文件共 52 条 prompt-completion 样本 + 1 份结构化知识文档, 覆盖 8 个知识类别

2.7 LLM 微调与推理测试

阶段	模型	通过率	关键问题
基础模型推理	Qwen2.5-0.5B-Instruct (未微调)	1/10 (10%)	缺乏 NURBS 领域知识和平台实测数据
QLoRA 微调后	Qwen2.5-0.5B + LoRA adapter	3/10 (30%)	continuity 类别数值混淆、recess/bulge 术语缺失
RAG 检索增强	微调模型 + RAG	7/10 (70%)	Q1 术语缺失、Q3 数值混淆、Q10 术语缺失

30% 通过率根因分析 (7 道失败题) :

- 缺乏平台特定数据: 43% (3 题)
 - 专业词汇缺失: 29% (2 题)
 - 概念定义错误: 14% (1 题)
 - 拒答模式: 14% (1 题)
 - 高风险类别 (100% 失败) : continuity、nurbs_basics、parametric_design、quality_assessment
-

三、8月10日 LLM 修复记录

3.1 系统提示词结构重构

文件: `scripts/llm_server.py` L33-L77、`scripts/Modelfile` L10-L54

修复项	修复前	修复后
关键数据位置	实测数值散落在速查表中	body↔front 和 body↔rear 两条数据置顶在 ⚠ 最重要 块
防混淆警告	无	明确警告「绝对不要把 recess/bulge 大间隙数值当成车身与保险杠的 G0」
G1 连续性定义	仅写「切向量连续」	补充「切向量方向一致，即法向量夹角 < 1.0 度（1度）」
速查表分类	平铺罗列所有配对	按「【共享边界】/【recess】/【bulge】」三大类显式分隔
领域知识	仅 NURBS 数学	新增 SOP 统计、SAE 坐标系、LWHWB 默认参数、CV/R 角数值

3.2 RAG 检索意图路由

文件: `scripts/llm_server.py` L302-L334 `retrieve()` 函数

意图检测	动作	效果
"车身 + 前保险杠 + 连续性"	<code>body↔front_bumper</code> 块 +50 分, <code>continuity_summary</code> +30 分	正确配对块排第 1
grille/headlight/taillight 块	未明确提问时 -20 分	干扰项（3.294mm）排到第 5
"间隙正常/修复"	wheel/hub/mirror/bumper 组件 +20 分	Q10 装配间隙术语更易命中

3.3 验证结果

测试	修复前	修复后	关键词命中
Q1 G1 连续性定义	FAIL (0/4)	PASS (4/4)	切向量 / 法向量 / 1度 / 共享边界
Q3 车身↔前保险杠 G0/G1	FAIL (1/2, 返回 3.294mm/88.814deg)	PASS (2/2)	0.000 / 0.131

3.4 两文件一致性验证

- `llm_server.py` 与 `Modelfile` 的系统提示词字节级完全一致
- 14 个关键锚点全部命中（实测数据、切向量/法向量、三大分类、SOP 统计、SAE 坐标系等）

- 5 个 RAG 路由锚点全部命中 (意图检测、加权 +50、抑制 -20 等)

3.5 Docker 容器化

新增文件:

文件	用途
Dockerfile.llm	LLM 推理服务镜像 (python:3.11-slim + torch CPU + transformers)
docker-compose.llm.yml	一键启动 llm-server 服务, 挂载 merged_model + 知识库
scripts/docker-llm.ps1	PowerShell 一键管理脚本 (up / logs / test / status / down / restart)

端到端测试 (本地环境模拟容器):

- 服务启动: 模型加载完成 (494M params) , RAG 开启 (20 个知识块)
- Q1: **4/4 PASS** — 「切向量方向在共享边界处保持一致, 即法向量夹角小于1度」
- Q3: **2/2 PASS** — 「body↔front_bumper G0=0.000mm, G1=0.131deg」

注: Docker Desktop daemon 今日未启动, 采用本地相同依赖环境 (transformers 4.57.6 + torch 2.4.1 CPU) 模拟容器行为验证。Docker Desktop 就绪后执行 `.\scripts\docker-llm.ps1` 即可一键构建+启动+测试。

四、关键指标现状

指标	状态	说明
单元测试	201 / 201 通过	8 月 9 日最近一次全量运行
LLM 10 题基准	7 / 10 通过 (70%)	Q1/Q3 修复后提升, Q10 待重跑
LLM Q1 + Q3	全过	Q1 4/4、Q3 2/2
LLM 服务	运行中	端口 11434, RAG 20 块加载正常
Docker 主平台	就绪	Dockerfile + docker-compose.yml
Docker LLM 服务	就绪	Dockerfile.llm + docker-compose.llm.yml + docker-llm.ps1
Git 分支	v1.01-reconstruct	最新 commit c6a65af3

五、遗留事项与建议

优先级	事项	说明
高	Q10 重跑验证	已执行：原始问题 1/6 FAIL，模型不使用中文术语，详见 3.5 节
高	Docker Desktop 启动后构建	daemon 就绪后执行 <code>.\scripts\docker-llm.ps1</code> 验证真实容器环境
中	模型容量瓶颈	0.5B 模型对长提示词记忆有限，如 Q10 仍失败可考虑切换 7B 模型
中	全量 10 题回归	当前仅重跑 Q1/Q3，建议跑完整 10 题确认无回退
低	训练数据扩充	当前 63 条 JSONL，可扩充至 500+ 条进一步提升覆盖面

六、文件变更清单（8/9 ~ 8/10）

修改文件

文件	变更内容
<code>src/config/carPresets.js</code>	新增 <code>generatePresetImage()</code> ，预渲染本地 SVG dataURL
<code>src/views/Designer.vue</code>	删除远程图片加载死代码，改用本地预置图
<code>scripts/llm_server.py</code>	系统提示词重构（L33-77）+ RAG 意图路由（L302-334）
<code>scripts/Modelfile</code>	系统提示词同步更新（L10-54）
<code>.gitignore</code>	新增 <code>data/exports/model_*/</code> 和 <code>data/step/nurbs_a_class_*.png</code>

新增文件

文件	用途
Dockerfile.llm	LLM 推理服务 Docker 镜像定义
docker-compose.llm.yml	LLM 服务 Docker Compose 编排
scripts/docker-llm.ps1	Docker 一键管理脚本
scripts/deploy_finetuned.py	QLoRA 微调 + 合并 + GGUF 转换自动化管线
scripts/train_qlora.py	QLoRA 训练脚本
scripts/merge_lora.py	LoRA adapter 合并脚本
scripts/analyze_failures.py	推理测试失败分析脚本
scripts/test_nurbs_inference.py	NURBS 专家模型推理测试脚本
scripts/setup_ollama.ps1	Ollama 环境配置脚本
data/training/parametric_design_knowledge.json	RAG 知识库（20 个知识块）
data/training/qlora_enhanced_dataset.jsonl	QLoRA 训练数据（63 条）
data/training/nurbs_surface_dataset.jsonl	NURBS 曲面训练数据
data/training/a_surface_quality_dataset.jsonl	A 级曲面质量训练数据
data/training/test_results.json	10 题推理测试结果
data/training/merged/merged_model/	合并后微调模型（~1.9GB）
data/training/nurbs-qwen-lora/	LoRA adapter + 3 个 checkpoint

归档文件

- ~80+ 个非核心文件移至 `_archive/`（详见 2.2 节）